


Instituto Federal de Educação, Ciência e Tecnologia de Brasília, campus Taguatinga,
Campus Taguatinga

# ESTUDO EXPERIMENTAL: AVALIAÇÃO COMPARATIVA DE ALTERNATIVAS AO MINIO PARA ARMAZENAMENTO DE OBJETOS EM ARQUITETURAS DE DATA LAKE HÍBRIDAS

**Por**

***ERICK SOUSA SARAIVA***

**Trabalho de Graduação**

BRASÍLIA/2026

Erick Sousa Saraiva

# ESTUDO EXPERIMENTAL: AVALIAÇÃO COMPARATIVA DE ALTERNATIVAS AO MINIO PARA ARMAZENAMENTO DE OBJETOS EM ARQUITETURAS DE DATA LAKE HÍBRIDAS

*Trabalho apresentado ao Curso de Bacharelado em Ciência da Computação do Instituto Federal de Educação, Ciência e Tecnologia de Brasília, campus Taguatinga, como requisito parcial para obtenção do grau de Bacharel em Bacharelado em Ciência da Computação.*

*Orientador:* Fabiano Cavalcanti Fernandes

BRASÍLIA
2026

Erick Sousa Saraiva

Estudo experimental: Avaliação comparativa de alternativas ao MinIO para armazenamento de objetos em arquiteturas de data lake híbridas/ Erick Sousa Saraiva. – BRASÍLIA, 2026-

40 p. : il. (algumas color.) ; 30 cm.

Orientador Fabiano Cavalcanti Fernandes

Trabalho de Graduação – Instituto Federal de Educação, Ciência e Tecnologia de Brasília, *campus* Taguatinga,, 2026.

1. Palavra-chave1. 2. Palavra-chave2. I. Orientador. II. Universidade xxx. III. Faculdade de xxx. IV. Título

CDU 004

Trabalho de Graduação apresentado por **Erick Sousa Saraiva** ao curso de Bacharelado em Ciência da Computação do Instituto Federal de Educação, Ciência e Tecnologia de Brasília, *campus* Taguatinga, sob o título **Estudo experimental: Avaliação comparativa de alternativas ao MinIO para armazenamento de objetos em arquiteturas de data lake híbridas**, orientado pelo **Prof. Fabiano Cavalcanti Fernandes** e aprovado pela banca examinadora formada pelos professores:

---

Prof. Fabiano Cavalcanti Fernandes
Computação/IFB

---

Prof. Leandro Vaguetti
Computação/IFB

---

Prof. Roberto Duarte Fontes
Computação/IFB

---

Prof. Raimundo Cláudio da Silva Vasconcelos
Computação/IFB

---

Prof. Daniel Saad Nogueira Nunes
Computação/IFB

BRASÍLIA
2026

*Aos familiares, amigos e professores que apoiam esta trajetória.*

# Agradecimentos

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

Nulla malesuada porttitor diam. Donec felis erat, congue non, volutpat at, tincidunt tristique, libero. Vivamus viverra fermentum felis. Donec nonummy pellentesque ante. Phasellus adipiscing semper elit. Proin fermentum massa ac quam. Sed diam turpis, molestie vitae, placerat a, molestie nec, leo. Maecenas lacinia. Nam ipsum ligula, eleifend at, accumsan nec, suscipit a, ipsum. Morbi blandit ligula feugiat magna. Nunc eleifend consequat lorem. Sed lacinia nulla vitae enim. Pellentesque tincidunt purus vel magna. Integer non enim. Praesent euismod nunc eu purus. Donec bibendum quam in tellus. Nullam cursus pulvinar lectus. Donec et mi. Nam vulputate metus eu enim. Vestibulum pellentesque felis eu massa.

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

Resumo

Este trabalho propõe um estudo experimental para avaliar comparativamente alternativas ao MinIO para armazenamento de objetos em arquiteturas de *Data Lake* híbridas. A pesquisa utilizará o MinIO como *baseline* e incluirá obrigatoriamente o RustFS, além de outras soluções selecionadas a partir de um mapeamento sistemático da literatura. Serão analisados desempenho, compatibilidade com a API S3, interoperabilidade com AWS, Azure e GCP, consumo de recursos, custos, licenciamento, maturidade, governança, sustentabilidade e riscos tecnológicos. O mapeamento sistemático identificará dimensões, métricas e lacunas relevantes para orientar a construção de um ambiente experimental padronizado.

**Palavras-chave:** Armazenamento de objetos, Data Lake, MinIO, RustFS, API S3, nuvem híbrida.

Abstract

This work proposes an experimental study to comparatively evaluate alternatives to MinIO for object storage in hybrid *Data Lake* architectures. MinIO will be used as the baseline, and RustFS will be included among the evaluated solutions, together with other alternatives selected through a systematic mapping study. The analysis will cover performance, S3 API compatibility, interoperability with AWS, Azure and GCP, resource consumption, costs, licensing, maturity, governance, sustainability, and technological risks. The systematic mapping will identify relevant dimensions, metrics, and research gaps to guide the construction of a standardized experimental environment.

**Keywords:** Object storage, Data Lake, MinIO, RustFS, S3 API, hybrid cloud.

Lista de Figuras

3.1 Fluxo do mapeamento sistemático da literatura . . . . . 22
3.2 Distribuição dos estudos primários por categoria e ano . . . . . 27

Lista de Blocos de Código

Lista de Tabelas

3.1 Critérios de inclusão. . . . . 24
3.2 Critérios de exclusão. . . . . 24
3.3 Funil de seleção dos estudos. . . . . 26
3.4 Exclusões no primeiro estágio, por critério. . . . . 26
3.5 Sistemas de armazenamento de objetos avaliados nos estudos primários. . . . . 27
3.6 Derivação dos elementos do laboratório a partir dos achados do mapeamento. . 30

A.1 Estudos primários selecionados no mapeamento sistemático. . . . . 34
A.2 Instrumentação e sistemas avaliados nos estudos primários. . . . . 36

Lista de Acrônimos

Sumário

**1 Introdução** **13**
1.1 Contextualização . . . 13
1.2 Análise do Problema . . . 14
1.3 Justificativa . . . 15
1.4 Proposta . . . 15
1.5 Objetivos . . . 16
1.5.1 Objetivo Geral . . . 16
1.5.2 Objetivos Específicos . . . 16
1.6 Escopo . . . 17
1.6.1 Delimitações fixadas a priori . . . 17
1.6.2 Parâmetros derivados do mapeamento sistemático . . . 18
1.6.3 Fora do escopo . . . 18
1.7 Organização do Trabalho . . . 19

**2 Fundamentação Teórica** **20**
2.1 Arquiteturas de *Data Lake* . . . 20
2.2 Armazenamento de objetos e API S3 . . . 20
2.3 Critérios de avaliação . . . 20

**3 Mapeamento Sistemático da Literatura** **21**
3.1 Visão geral do método . . . 21
3.2 Questões de pesquisa . . . 22
3.3 Estratégia de busca . . . 23
3.3.1 Calibração da busca . . . 23
3.4 Critérios de inclusão e exclusão . . . 23
3.5 Processo de seleção . . . 24
3.5.1 Apoio de modelo de linguagem . . . 25
3.6 Categorias de análise . . . 25
3.7 Resultados . . . 25
3.8 Respostas às questões de pesquisa . . . 27
3.8.1 QP1 — Soluções identificadas . . . 27
3.8.2 QP2 — Dimensões e métricas . . . 28
3.8.3 QP3 — Procedimentos experimentais . . . 28
3.8.4 QP4 — Fatores não funcionais . . . 29
3.8.5 QP5 — Lacunas apontadas . . . 29
3.9 Derivação dos critérios do laboratório . . . 29
3.10 Limitações do mapeamento . . . 29

**4 Metodologia** **32**

**5 Considerações finais** **33**

**A Instrumentos do Mapeamento Sistemático** **34**

A.1 Estudos primários selecionados . . . . . 34

A.2 Instrumentação e sistemas avaliados . . . . . 36

**Referências** **40**

# 1

# Introdução

## 1.1 Contextualização

A crescente demanda por processamento e análise de grandes volumes de dados impulsionou a adoção de arquiteturas de *Data Lake*, que permitem o armazenamento centralizado de dados brutos em diferentes formatos: estruturados, semiestruturados e não estruturados, sem necessidade de transformação prévia (TAST; MOSEVA, 2026). Nesse sentido, o armazenamento é desacoplado do processamento, favorecendo flexibilidade e escalabilidade. Essa característica torna o *Data Lake* amplamente utilizado em pipelines de aprendizado de máquina e análise de dados em larga escala, nos quais ele atua como repositório central para dados de diferentes fontes, como vídeos, imagens e documentos.

Em cenários de nuvem híbrida, organizações que buscam mitigar riscos de soberania de dados e de dependência de fornecedor (*vendor lock-in*) optam por manter parte da infraestrutura de armazenamento *on-premises*, replicando funcionalidades oferecidas por provedores como Amazon Web Services (AWS), Microsoft Azure e Google Cloud Platform (GCP). A camada de armazenamento de objetos é componente central nessas arquiteturas, e o protocolo S3 da AWS consolidou-se como padrão de fato para interoperabilidade entre sistemas (TAST; MOSEVA, 2026).

Nesse contexto, o MinIO tornou-se uma solução amplamente utilizada para armazenamento de objetos compatível com a API S3 em arquiteturas de *Data Lake* híbridas (ABDEL Raziq Al Otaibi, 2026). Ao longo dos anos, a empresa responsável pelo projeto promoveu mudanças progressivas em seu modelo de distribuição e licenciamento: em 2021, a licença foi alterada de Apache 2.0 para GNU AGPLv3; em maio de 2025, a interface de administração web foi removida da edição comunitária; em outubro de 2025, as distribuições binárias pré-compiladas foram descontinuadas, passando a edição comunitária a ser distribuída apenas como código-fonte; e em fevereiro de 2026, o repositório público foi oficialmente marcado como não mantido (*THIS REPOSITORY IS NO LONGER MAINTAINED*), com correções de segurança passando a ser avaliadas caso a caso, sem garantias (MinIO, Inc., 2026; DevPro, 2025; FAUN Dev, 2026). O suporte ativo, os binários e as funcionalidades completas de administração foram concentrados no produto comercial MinIO AIStor, disponível por assinatura.

Esse cenário expõe organizações que basearam sua camada de armazenamento de objetos no MinIO a riscos concretos de segurança e de sustentabilidade tecnológica, tornando relevante a avaliação de alternativas viáveis com licenciamento aberto e compatibilidade com a API S3, além da governança de dados, para mitigar riscos de dependência tecnológica e de *vendor lock-in*.

## 1.2 Análise do Problema

O problema central desta pesquisa é a dependência tecnológica de organizações em relação ao MinIO como solução de armazenamento de objetos em arquiteturas de *Data Lake* híbridas, agravada pelas mudanças unilaterais e progressivas promovidas pelo fornecedor em seu modelo de licenciamento e distribuição.

Em ambientes de nuvem híbrida, a camada de armazenamento de objetos compatível com a *API* S3 ocupa posição crítica na pilha de dados: dela dependem pipelines de ingestão, ferramentas de processamento distribuído, serviços de análise e mecanismos de governança. A substituição dessa camada implica riscos operacionais elevados, o que leva organizações a manter por longos períodos a solução inicialmente adotada, aprofundando a dependência.

O MinIO foi amplamente adotado por oferecer compatibilidade com a *API* S3 sob licenciamento livre e distribuição binária sem custo. Contudo, a migração para licença GNU AGPLv3 em 2021, a remoção da interface de administração web da edição comunitária em maio de 2025, a descontinuação das distribuições binárias pré-compiladas em outubro de 2025 e o arquivamento oficial do repositório público em fevereiro de 2026 (MinIO, Inc., 2026; DevPro, 2025; FAUN Dev, 2026) configuraram uma ruptura progressiva com a comunidade de usuários que baseava sua operação na edição livre da ferramenta. Organizações nessa situação enfrentam hoje a escolha entre permanecer com uma base de código não mantida, migrar para o produto comercial ou substituir a camada de armazenamento por uma alternativa, e a literatura ainda não oferece subsídios empíricos sistematizados para orientar essa decisão.

O enfrentamento desse problema esbarra, porém, em uma dificuldade metodológica anterior. Não se sabe, de antemão, **quais** alternativas existem sob licenciamento aberto e com compatibilidade efetiva com a *API* S3, nem **segundo quais critérios** essas alternativas deveriam ser comparadas. Definir arbitrariamente um conjunto de soluções e métricas de avaliação produziria uma comparação cujos resultados seriam, no limite, um artefato das escolhas iniciais do pesquisador, e não uma caracterização defensável do estado da arte.

As dimensões relevantes para avaliar armazenamento de objetos em contexto híbrido, as métricas que as operacionalizam, os cenários de carga representativos e os fatores qualitativos pertinentes constituem, eles próprios, objeto de investigação. O problema desta pesquisa comporta, portanto, dois níveis encadeados: um nível de levantamento, que consiste em estabelecer de forma sistemática e rastreável quais soluções e quais critérios de avaliação a literatura reconhece como pertinentes; e um nível experimental, que consiste em aplicar esses critérios em ambiente controlado para caracterizar o comportamento das soluções frente ao *baseline*. O primeiro nível

condiciona o segundo, e é essa dependência que a metodologia adotada neste trabalho procura tornar explícita.

## 1.3 Justificativa

As mudanças progressivas no modelo de distribuição e licenciamento do MinIO representam um risco concreto para organizações públicas e privadas que adotaram a solução como componente central de sua infraestrutura de dados. A descontinuação das distribuições binárias e o congelamento do desenvolvimento comunitário em 2025, seguidos pelo arquivamento do repositório público em fevereiro de 2026 (FAUN Dev, 2026; MinIO, Inc., 2026), comprometem a previsibilidade operacional de ambientes que dependem da solução, especialmente em contextos de nuvem híbrida onde soberania de dados e controle sobre a infraestrutura são requisitos críticos.

Trabalhos recentes já comparam sistemas de armazenamento de objetos de código aberto (TAST; MOSEVA, 2026). Contudo, até o momento não foram identificados estudos que avaliem alternativas ao MinIO considerando, de forma conjunta, o contexto de arquiteturas de *Data Lake* híbridas, a compatibilidade com provedores de nuvem, a sustentabilidade do licenciamento e os riscos de dependência tecnológica, incluindo soluções emergentes como o RustFS. Essa lacuna foi confirmada pelo mapeamento sistemático descrito no Capítulo 3, que não identificou nenhum estudo revisado por pares avaliando o RustFS. Os resultados poderão orientar equipes de engenharia de dados na seleção de tecnologias mais sustentáveis, contribuindo para a redução de riscos de segurança e de *vendor lock-in*, assim como para o fortalecimento do domínio na área de governança de dados.

## 1.4 Proposta

Este trabalho propõe um estudo experimental para avaliar comparativamente ao menos três soluções de armazenamento de objetos compatíveis com a API S3, além do MinIO como *baseline* de referência, sendo o RustFS uma das alternativas obrigatoriamente incluídas. As demais soluções foram selecionadas a partir dos resultados do mapeamento sistemático, priorizando projetos com licenciamento aberto e adoção ativa pela comunidade.

A avaliação é conduzida por meio de um cenário de migração. Em vez de comparar as soluções isoladamente, o laboratório reproduz a situação concreta enfrentada pelas organizações afetadas: a transferência de um acervo de objetos do MinIO para uma solução alternativa, seguida da verificação de que o acervo permaneceu íntegro e de que as operações que dependiam dele continuam funcionando. Essa escolha mantém o experimento ancorado no problema descrito na Seção 1.2, cuja terceira saída é justamente a substituição da camada de armazenamento.

Cabe esclarecer que o cenário de migração é o instrumento da comparação, e não uma demonstração de viabilidade. A pergunta que o laboratório responde é se cada alternativa sustenta uma migração adequada, e a que custo, admitindo-se que a resposta possa ser negativa para parte

das soluções avaliadas.
A pesquisa adota como princípio metodológico a rastreabilidade entre levantamento e experimentação: cada solução avaliada, cada dimensão de comparação, cada métrica coletada e cada cenário executado deve remeter a um achado documentado do mapeamento sistemático. Nenhum item do desenho experimental será introduzido sem referência ao estudo que o fundamenta ou, na ausência de precedente na literatura, sem justificativa explícita de que constitui contribuição original do trabalho. Essa cadeia de derivação está documentada na Seção 3.9 e é instanciada no Capítulo 4.

## 1.5 Objetivos

### 1.5.1 Objetivo Geral

O objetivo geral é avaliar comparativamente alternativas ao MinIO para armazenamento de objetos em arquiteturas de *Data Lake* híbridas, por meio de um cenário de migração, considerando as dimensões de comparação identificadas no mapeamento sistemático da literatura, em especial desempenho, compatibilidade com a API S3, integridade dos dados transferidos e riscos tecnológicos.

### 1.5.2 Objetivos Específicos

São objetivos específicos deste trabalho:

- Identificar soluções de armazenamento de objetos compatíveis com a API S3 que possam constituir alternativas ao MinIO em arquiteturas híbridas;
- Caracterizar os requisitos técnicos relevantes para armazenamento de objetos em arquiteturas de *Data Lake* híbridas;
- Levantar, a partir da literatura, as dimensões, métricas e procedimentos experimentais empregados na avaliação desse tipo de solução;
- Especificar um ambiente experimental padronizado para implantação das soluções selecionadas e execução do cenário de migração;
- Definir os indicadores que caracterizam uma migração bem-sucedida, abrangendo integridade dos objetos, cobertura das operações da API S3 e custo da transferência;
- Analisar comparativamente as soluções segundo modelo de licenciamento, maturidade do projeto e riscos tecnológicos.

## 1.6 Escopo

Este trabalho delimita-se à avaliação comparativa experimental de soluções de armazenamento de objetos compatíveis com a *API* S3, implantadas *on-premises* no contexto de arquiteturas de *Data Lake* híbridas. A delimitação opera em dois níveis distintos: um conjunto de restrições fixadas *a priori*, descritas na próxima seção, que decorrem diretamente da formulação do problema; e um conjunto de parâmetros deliberadamente mantidos em aberto, cuja definição é produto do mapeamento sistemático da literatura descrito no Capítulo 3.

### 1.6.1 Delimitações fixadas a priori

São fixadas previamente apenas as restrições que decorrem da natureza do problema investigado ou de decisões de viabilidade, as quais não dependem de achados do mapeamento sistemático. São elas:

- **Objeto de estudo.** Soluções de armazenamento de objetos que implementem a *API* S3, considerada padrão de fato para interoperabilidade nessas arquiteturas (TAST; MOSEVA, 2026). Sistemas de arquivos distribuídos que não exponham interface compatível com S3 não integram o estudo.
- ***Baseline* de referência.** O MinIO, por ser a solução cuja descontinuidade origina o problema.
- **Cenário experimental.** A comparação é conduzida por meio da migração de um acervo de objetos a partir do MinIO, por corresponder à decisão concreta enfrentada pelas organizações afetadas.
- **Licenciamento aberto.** Apenas soluções sob licença de código aberto são consideradas.
- **Alternativa obrigatória.** O RustFS integra o conjunto avaliado por definição prévia da pesquisa.
- **Cardinalidade mínima.** Serão avaliadas ao menos três soluções, além do *baseline*, de modo que a comparação não se reduza a um confronto bilateral.
- **Ambiente de execução.** Os experimentos serão conduzidos em ambiente laboratorial controlado e padronizado, com conjuntos de dados sintéticos ou públicos de referência.
- **Custos.** Entende-se por custos os custos de licenciamento e de operação estimados para cada solução, excluindo a aquisição de infraestrutura física.

### 1.6.2 Parâmetros derivados do mapeamento sistemático

Os elementos a seguir **não** são fixados neste capítulo, por constituírem resultado do mapeamento sistemático e não premissa dele. Eles são o elo entre o levantamento e a experimentação:

- a identificação das demais soluções que comporão o conjunto avaliado, ou seja, quais produtos alternativos ao MinIO;
- as dimensões de comparação pertinentes à avaliação em contexto híbrido, ou seja, quais aspectos do armazenamento de objetos são relevantes para a análise;
- as métricas, os procedimentos de medição e os critérios de validade, isto é, o que será usado no laboratório para avaliar cada dimensão;
- os cenários de carga e as características dos conjuntos de dados;
- os critérios de verificação da compatibilidade com a *API* S3 e da integridade dos objetos após a migração;
- os fatores qualitativos relevantes, como licenciamento, governança, maturidade e riscos tecnológicos;
- as lacunas de pesquisa que o desenho experimental se propõe a endereçar.

A definição desses parâmetros está sujeita ao suporte encontrado na literatura e à capacidade do ambiente laboratorial disponível. Elementos fundamentados que excedam essa capacidade são registrados como limitação declarada.

### 1.6.3 Fora do escopo

Não integram este trabalho: o desenvolvimento de novas soluções de armazenamento; a avaliação de ferramentas proprietárias ou de código fechado; pipelines de dados em produção real; a integração com motores de processamento específicos, como Apache Spark ou Apache Flink; experimentos conduzidos diretamente na infraestrutura de organizações; e os custos de aquisição de hardware físico.

Por se tratar do Projeto de Conclusão de Curso, este documento apresenta o mapeamento sistemático concluído e a especificação do laboratório experimental. A execução dos experimentos e a análise de seus resultados constituem o Trabalho de Conclusão de Curso, etapa subsequente.

## 1.7 Organização do Trabalho

Este trabalho está organizado em cinco capítulos, encadeados de modo que cada um forneça os insumos do seguinte.

O Capítulo 1, *Introdução*, apresenta o contexto da pesquisa, a análise do problema, a justificativa, a proposta, os objetivos, o escopo e esta seção de organização.

O Capítulo 2, *Fundamentação Teórica*, estabelece o vocabulário conceitual necessário à leitura dos capítulos subsequentes, tratando de *Data Lake* e *Data Lakehouse*, armazenamento de objetos, *API* S3, computação em nuvem híbrida, soberania de dados, *vendor lock-in*, licenciamento de software livre e armazenamento distribuído.

O Capítulo 3, *Mapeamento Sistemático da Literatura*, documenta a execução do mapeamento conduzido segundo as diretrizes de (PETERSEN; VAKKALANKA; KUZNIARZ, 2015) e (KITCHENHAM et al., 2010). Abrange a definição das questões de pesquisa, a estratégia de busca, os critérios de inclusão e exclusão, o processo de seleção em três estágios, a classificação dos estudos por categorias de análise, a extração de dados e a síntese dos resultados. Esse capítulo fornece o conjunto de soluções a avaliar, as dimensões de comparação, as métricas correspondentes e as lacunas que o experimento endereça, fundamentando a escolha de cada métrica, cenário e solução do laboratório.

O Capítulo 4, *Metodologia*, especifica o laboratório experimental a partir dos achados do capítulo anterior, detalhando o ambiente de testes, os conjuntos de dados, o cenário de migração, os indicadores coletados, o número de repetições, os procedimentos de análise e o cronograma de execução.

Por fim, o Capítulo 5, *Considerações Finais*, sintetiza o que foi estabelecido nesta etapa, explicita as limitações do trabalho e descreve o que será realizado no Trabalho de Conclusão de Curso.

# 2

# Fundamentação Teórica

Este capítulo apresenta os conceitos que fundamentam a avaliação comparativa de soluções de armazenamento de objetos em arquiteturas de *Data Lake* híbridas. São discutidos os conceitos de *Data Lake*, armazenamento de objetos, compatibilidade com a API S3, implantação *on-premises* e em nuvem, além dos critérios de desempenho, governança e sustentabilidade tecnológica que orientam o estudo experimental.

## 2.1 Arquiteturas de *Data Lake*

*Data Lakes* armazenam dados em diferentes formatos e permitem que o processamento seja realizado de forma desacoplada da camada de armazenamento. Em arquiteturas híbridas, parte dos dados e dos serviços permanece sob controle da organização, enquanto outra parte utiliza recursos de provedores de nuvem.

## 2.2 Armazenamento de objetos e API S3

O armazenamento de objetos organiza os dados como objetos associados a metadados e identificadores, normalmente agrupados em contêineres. A API S3 tornou-se uma referência de interoperabilidade para esse modelo, permitindo que aplicações utilizem diferentes implementações com alterações reduzidas.

## 2.3 Critérios de avaliação

A comparação das soluções considera desempenho, compatibilidade, operação, licenciamento, governança e sustentabilidade. Esses critérios são detalhados e operacionalizados a partir dos achados do mapeamento sistemático apresentado no Capítulo 3.

# 3

# Mapeamento Sistemático da Literatura

Este capítulo descreve o mapeamento sistemático da literatura realizado para fundamentar o laboratório experimental. O mapeamento não é um fim em si mesmo: ele existe para responder a uma pergunta prática. Quais alternativas avaliar, com quais métricas e com quais ferramentas? Essas escolhas poderiam ser feitas por intuição, mas o resultado seria frágil. Ao derivá-las da literatura, cada decisão do experimento passa a ter uma origem verificável.

O capítulo termina na Seção 3.9, que liga cada elemento do laboratório ao achado que o justifica.

## 3.1 Visão geral do método

Um mapeamento sistemático é uma forma estruturada de revisar a literatura. Em vez de reunir trabalhos por conveniência, define-se antes um protocolo: quais perguntas responder, onde buscar, o que incluir, o que descartar e como classificar o que sobrar. Só depois a busca é executada. Isso torna o processo auditável e permite que outra pessoa o repita.

O protocolo seguiu as diretrizes de (PETERSEN; VAKKALANKA; KUZNIARZ, 2015), específicas para estudos de mapeamento em engenharia de software, com apoio das recomendações de (KITCHENHAM et al., 2010) para revisões sistemáticas. A Figura 3.1 apresenta o fluxo completo.

Todas as etapas automatizáveis foram implementadas em um *notebook* Python, aqui chamado de protocolo executável. O *notebook* realiza a consulta às bases, a normalização e a deduplicação dos registros, a geração das planilhas de triagem, a consolidação das decisões e a produção das figuras e tabelas deste capítulo. Os números apresentados adiante são saída direta desse código, e não contagens feitas à mão. Reexecutar o *notebook* regenera o conjunto de dados e, com ele, os valores reportados.

Duas etapas não são automatizáveis e couberam ao autor: a leitura dos estudos e a decisão sobre incluí-los ou não. Um modelo de linguagem foi usado como apoio na pré-classificação e na leitura dirigida, conforme detalhado na Seção 3.5, mas nenhuma decisão de inclusão ou exclusão foi tomada por ele.

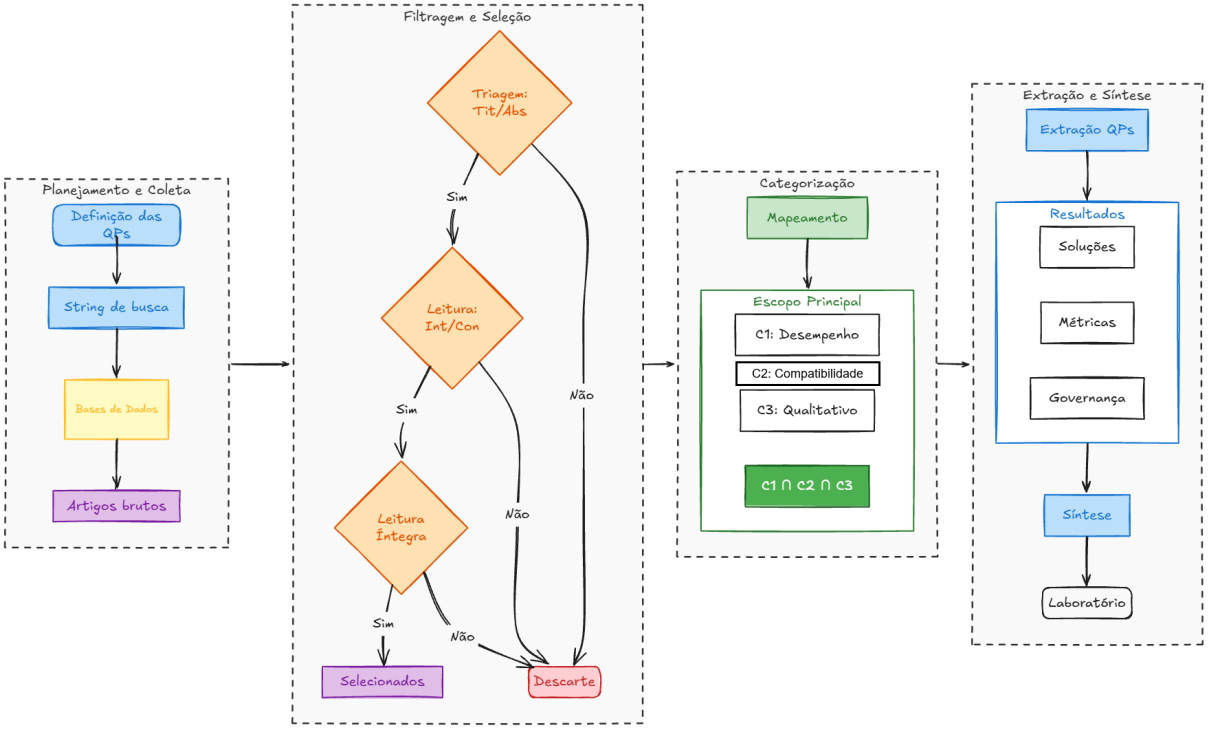



**Figura 3.1:** Fluxo do mapeamento sistemático da literatura

**Fonte:** Elaborado pelo autor (2026).

## 3.2 Questões de pesquisa

As questões abaixo orientaram a extração de dados. Elas são formuladas como perguntas de levantamento, e não como hipóteses. A diferença é importante: perguntar quais métricas a literatura usa é diferente de perguntar qual é o desempenho de uma solução. A primeira forma permite que o conjunto de métricas do experimento venha do levantamento; a segunda já suporia esse conjunto definido.

**QP1.** Quais sistemas de armazenamento de objetos compatíveis com a *API* S3 e de código aberto são reportados na literatura como aplicáveis a arquiteturas de *Data Lake* ou de nuvem híbrida?

**QP2.** Quais dimensões e métricas são empregadas para avaliar comparativamente esses sistemas?

**QP3.** Quais procedimentos experimentais — cargas de trabalho, conjuntos de dados, ferramentas de *benchmark* e número de repetições — são adotados nessas avaliações?

**QP4.** Quais fatores não funcionais — licenciamento, governança, maturidade, comunidade e risco de descontinuidade — são considerados na seleção dessas soluções?

**QP5.** Que lacunas de pesquisa são apontadas pelos próprios autores dos estudos analisados?

Cada questão alimenta uma parte do laboratório. A QP1 define quais soluções avaliar; a QP2, quais dimensões comparar; a QP3, como medir; a QP4, quais critérios qualitativos considerar; e a QP5 situa a contribuição deste trabalho em relação ao que já se sabe estar faltando.

## 3.3 Estratégia de busca

A expressão de busca foi montada a partir de três blocos de termos, combinados pelo operador `AND`. Dentro de cada bloco, os sinônimos são combinados por `OR`:

**Bloco A — o que é estudado.** `"object storage"`, `"object store"`, `"object-based storage"`, `"S3-compatible"`, `"S3 compatible"`, `"blob storage"`.

**Bloco B — em que contexto ou com qual tecnologia.** `"data lake"`, `"lakehouse"`, `"hybrid cloud"`, `"private cloud"`, `"on-premises"`, `"on-premise"`, `"MinIO"`, `"Ceph"`, `"SeaweedFS"`, `"RustFS"`, `"OpenStack Swift"`, `"JuiceFS"`, `"Garage S3"`, `"Zenko"`.

**Bloco C — que tipo de estudo.** `evaluation`, `benchmark`, `benchmarking`, `comparison`, `comparative`, `performance`, `assessment`.

Na prática, a busca foi executada como dez consultas menores derivadas dessa mesma estrutura, e não como uma expressão única. O motivo é técnico: a interface de busca da base utilizada trabalha por relevância e não processa bem expressões booleanas longas. A união dos resultados, depois da deduplicação, equivale ao que uma consulta única retornaria, com a vantagem de permitir reportar o rendimento de cada consulta em separado.

O recorte temporal vai de 2016 a 2026. O limite inferior corresponde ao período em que arquiteturas de *Data Lake* com armazenamento de objetos desacoplado do processamento se consolidaram e em que o MinIO passou a ser adotado.

### 3.3.1 Calibração da busca

Antes da execução definitiva, verificou-se se a expressão recuperava estudos previamente conhecidos. O trabalho de (TAST; MOSEVA, 2026), que compara sistemas de armazenamento de objetos de código aberto e é o antecedente mais próximo desta pesquisa, foi recuperado pela busca. Esse resultado indica que a expressão cobre o tema pretendido.

## 3.4 Critérios de inclusão e exclusão

Um estudo entra no corpus quando atende a todos os critérios de inclusão da Tabela 3.1. Basta atender a um dos critérios de exclusão da Tabela 3.2 para ser descartado.

**Tabela 3.1:** Critérios de inclusão.

| Código | Critério |
|---|---|
| CI1 | Aborda sistema de armazenamento de objetos com interface compatível com S3 |
| CI2 | Apresenta avaliação, comparação ou caracterização empírica de ao menos um sistema |
| CI3 | Publicado entre 2016 e 2026 |
| CI4 | Texto completo acessível |
| CI5 | Escrito em inglês ou português |

**Fonte:** Elaborado pelo autor (2026).

**Tabela 3.2:** Critérios de exclusão.

| Código | Critério |
|---|---|
| CE1 | Trata apenas de armazenamento em bloco ou de sistema de arquivos POSIX, sem camada de objetos |
| CE2 | Trata apenas de serviços proprietários de nuvem pública, sem contraparte que possa ser executada pela própria organização |
| CE3 | Não apresenta dado empírico nem critério de avaliação |
| CE4 | Estudo secundário sem contribuição própria |
| CE5 | Versão preliminar de trabalho publicado depois de forma mais completa |
| CE6 | Resumo expandido, pôster ou texto com menos de quatro páginas |
| CE7 | Texto completo indisponível após tentativa de acesso |

**Fonte:** Elaborado pelo autor (2026).

Estudos descartados por CE4 não foram perdidos: suas listas de referências foram examinadas em busca de trabalhos ainda não recuperados pela busca automatizada, procedimento conhecido como *snowballing* (WOHLIN, 2014).

## 3.5 Processo de seleção

A seleção ocorreu em três estágios, cada um aplicado apenas ao que foi aprovado no anterior. O objetivo é ler cada vez mais a respeito de cada vez menos trabalhos, sem precisar ler todos por inteiro.

No primeiro estágio, foram lidos o título e o resumo de cada registro. No segundo, a introdução e a conclusão dos aprovados. No terceiro, realizou-se leitura dirigida das seções de metodologia e avaliação experimental, voltada especificamente à extração dos dados das questões QP1 a QP5. Em toda exclusão foi registrado o código do critério aplicado, o que permite reconstruir o caminho de cada decisão.

Antes do primeiro estágio, um filtro automático de pertinência descartou registros que

não mencionavam, no título ou no resumo, nenhum termo do núcleo conceitual da pesquisa. Esse filtro removeu 495 registros sem leitura individual. Uma amostra desses descartes foi revisada manualmente para confirmar que o filtro não eliminava trabalhos pertinentes.

### 3.5.1 Apoio de modelo de linguagem

Um modelo de linguagem foi usado em duas etapas. No primeiro estágio, ele recebeu os critérios de inclusão e exclusão junto com o resumo de cada registro e produziu uma sugestão de decisão, acompanhada do critério invocado e de uma medida de confiança. No terceiro estágio, foi usado como apoio à leitura dirigida, para localizar nas seções de metodologia as informações de instrumentação, sistemas avaliados e cargas de trabalho.

Em nenhum momento o modelo decidiu pela inclusão ou exclusão de um estudo. Todas as sugestões de inclusão foram revisadas pelo autor, assim como uma amostra das sugestões de exclusão, e a decisão final foi sempre humana. Os dados extraídos na leitura dirigida foram conferidos contra os textos originais.

## 3.6 Categorias de análise

Os estudos aprovados foram classificados em três categorias não exclusivas, de modo que um mesmo trabalho pode pertencer a mais de uma:

**C1 — Avaliação de desempenho.** Reporta medidas de *throughput*, latência, IOPS, escalabilidade ou consumo de recursos.

**C2 — Compatibilidade e integração.** Trata da cobertura da *API* S3, da interoperabilidade entre sistemas ou de procedimentos de migração.

**C3 — Fatores qualitativos.** Aborda licenciamento, governança do projeto, maturidade, custo, consumo energético ou risco tecnológico.

A interseção das três categorias delimita o escopo central desta pesquisa. Um estudo que avalie ao mesmo tempo desempenho, compatibilidade e fatores qualitativos de soluções de armazenamento de objetos é o antecedente mais próximo deste trabalho, e a quantidade de estudos nessa posição indica o quanto o tema já foi coberto.

## 3.7 Resultados

A busca retornou 881 registros brutos. Após a remoção de duplicatas, restaram 771 registros únicos, que passaram pelos três estágios de seleção. A Tabela 3.3 apresenta o funil completo.

**Tabela 3.3:** Funil de seleção dos estudos.

| Etapa | Registros |
|---|---|
| Consultas executadas | 10 |
| Registros brutos recuperados | 881 |
| Registros únicos após deduplicação | 771 |
| Aprovados no estágio 1 (título e resumo) | 64 |
| Aprovados no estágio 2 (introdução e conclusão) | 38 |
| Estudos primários selecionados | 38 |

**Fonte:** Elaborado pelo autor (2026).

**Tabela 3.4:** Exclusões no primeiro estágio, por critério.

| Código | Motivo | Registros |
|---|---|---|
| CE1 | Não é armazenamento de objetos | 551 |
| CE3 | Sem dado empírico nem critério de avaliação | 114 |
| CE2 | Apenas serviço proprietário de nuvem pública | 21 |
| CE4 | Estudo secundário sem contribuição própria | 16 |
| CE5 | Versão preliminar de trabalho estendido | 4 |
| CE6 | Menos de quatro páginas | 1 |

**Fonte:** Elaborado pelo autor (2026).

Sete das dez consultas atingiram o teto de cem resultados estabelecido por consulta. Isso significa que a coleta foi interrompida por decisão de volume, e não porque a base tivesse se esgotado. A Tabela 3.4 detalha os motivos de exclusão no primeiro estágio.

Dos 551 registros excluídos por CE1, 495 foram descartados pelo filtro automático de pertinência e 56 por avaliação individual. Já o número de exclusões por CE3 merece atenção: 114 trabalhos tratavam de armazenamento de objetos, mas não apresentavam qualquer medição ou critério de avaliação. Esse dado indica que boa parte da produção sobre o tema é descritiva, e não empírica.

Entre os 38 estudos selecionados, 37 foram classificados em C1, 33 em C2 e 20 em C3. Dezoito estudos pertencem simultaneamente às três categorias. A Figura 3.2 mostra a distribuição por categoria e ano.

A figura revela dois padrões. O primeiro é a concentração recente: dos 38 estudos, 17 são de 2026 e nenhum é anterior a 2020, apesar de a busca abranger desde 2016. O segundo é o surgimento tardio da categoria C3. Enquanto trabalhos sobre desempenho e compatibilidade existem desde 2020, os que tratam de licenciamento, custo e governança só aparecem a partir de 2022. A discussão sobre sustentabilidade de soluções de armazenamento é, portanto, recente, o que é coerente com o problema investigado neste trabalho: as mudanças no modelo de licenciamento do MinIO começaram em 2021.

A relação completa dos estudos primários encontra-se no Apêndice A.

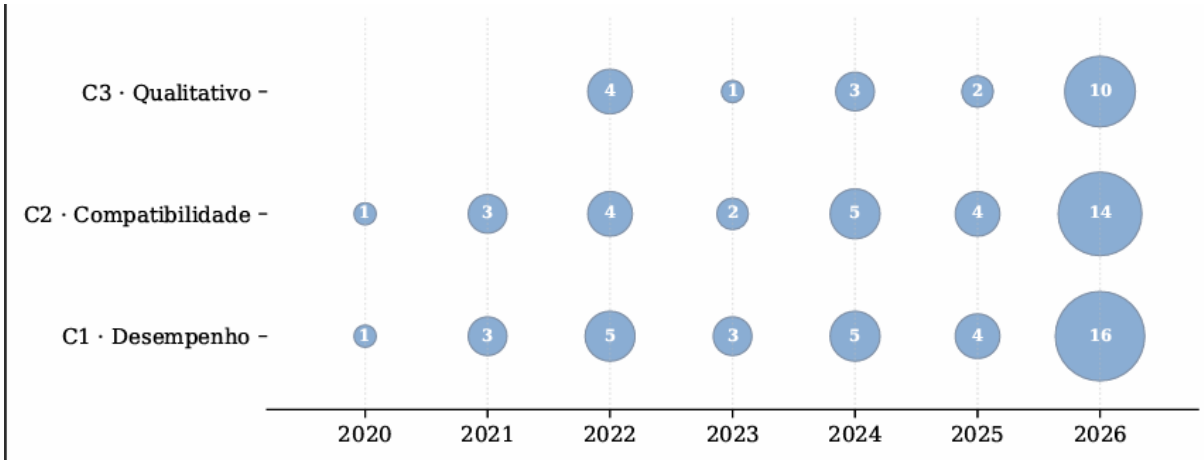



**Figura 3.2:** Distribuição dos estudos primários por categoria e ano

**Fonte:** Elaborado pelo autor (2026).

## 3.8 Respostas às questões de pesquisa

### 3.8.1 QP1 — Soluções identificadas

A Tabela 3.5 apresenta os sistemas avaliados nos estudos primários, contados por número de estudos distintos em que aparecem.

**Tabela 3.5:** Sistemas de armazenamento de objetos avaliados nos estudos primários.

| Sistema | Estudos |
|---|---|
| MinIO | 17 |
| Ceph | 11 |
| OpenStack Swift | 5 |
| Lustre | 2 |
| Garage | 1 |
| RustFS | 0 |
| SeaweedFS | 0 |

**Fonte:** Elaborado pelo autor (2026).

O MinIO é o sistema mais estudado, aparecendo em 17 dos 38 trabalhos. Esse dado acrescenta uma segunda justificativa à sua adoção como *baseline*: além de ser a solução cuja descontinuidade originou o problema, é a que dispõe de maior base de comparação na literatura.

Na outra ponta, o RustFS e o SeaweedFS não aparecem em nenhum estudo revisado por pares, e o Garage em apenas um. A lacuna prevista na análise do problema (Seção 1.2) confirma-se de forma quantitativa: as alternativas emergentes ao MinIO ainda não foram objeto de avaliação acadêmica.

### 3.8.2 QP2 — Dimensões e métricas

As métricas recorrentes nos estudos primários são *throughput* (16 estudos), latência (14), escalabilidade (11) e custo (10). Consumo de CPU e memória aparece em 5 estudos e disponibilidade em 4. Métricas como durabilidade e eficiência de *erasure coding* aparecem isoladamente.

Essas quatro primeiras métricas formam o conjunto de base para o laboratório. Elas não foram escolhidas por conveniência: são as que a literatura do domínio efetivamente emprega.

### 3.8.3 QP3 — Procedimentos experimentais

Este foi o achado mais relevante para o desenho do laboratório, e também o mais inesperado.

Quanto à instrumentação, 15 dos 38 estudos construíram a própria ferramenta de medição, na forma de *scripts* em Python, *harnesses* customizados ou rotinas específicas. A ferramenta estabelecida mais utilizada é o Warp, presente em apenas 3 estudos, seguida do MLPerf Storage e do IOR, com 2 cada. Ferramentas como COSBench, IO500, MDTest, S3bench e FIO aparecem uma vez cada.

Em outras palavras, não existe instrumentação padronizada para avaliação de sistemas de armazenamento de objetos. Cada grupo mede à sua maneira, o que compromete a comparabilidade entre resultados publicados. Esse achado tem duas consequências para este trabalho: justifica declarar a instrumentação de forma explícita e detalhada, e recomenda o uso do Warp, que é a ferramenta com maior respaldo para carga compatível com S3.

Quanto às cargas de trabalho, 30 dos 38 estudos declaram tamanhos de objeto. Três regimes se repetem:

**Metadados.** Objetos pequenos, de 1 KB a 64 KB, com listagem de conjuntos que vão de um a cem milhões de objetos. Avalia a capacidade do sistema de gerenciar grande quantidade de referências.

**Analítico.** Blocos de 16 MB a 128 MB, típicos de leitura de arquivos *Parquet* em *Data Lake*, sobre conjuntos de dados de dezenas a centenas de gigabytes.

**Arquivos grandes.** Objetos de 100 MB a 10 GB transferidos em *multipart*, com paralelismo que varia de 1 a 128 conexões simultâneas.

Quanto à confiabilidade das medidas, apenas 10 dos 38 estudos informam o número de repetições executadas. Entre os que informam, os valores vão de 3 a 50, com mediana de 5. A omissão desse dado em 28 estudos é, por si só, uma limitação recorrente na literatura do domínio.

### 3.8.4 QP4 — Fatores não funcionais

Vinte dos 38 estudos consideram ao menos um fator não funcional. Custo é o mais frequente, seguido de consumo energético, que aparece em trabalhos recentes associados à discussão de sustentabilidade ambiental. Licenciamento e governança do projeto aparecem com menos frequência e, em geral, de forma incidental: são mencionados como contexto da escolha de uma ferramenta, não como objeto de avaliação.

Nenhum dos estudos recuperados trata do risco de descontinuidade de uma solução de código aberto como critério de seleção, que é precisamente o fator que originou esta pesquisa.

### 3.8.5 QP5 — Lacunas apontadas

Três lacunas emergem do conjunto analisado. A primeira é a ausência de avaliação das alternativas emergentes: RustFS, SeaweedFS e Garage praticamente não aparecem, embora sejam apontadas na prática como substitutas do MinIO. A segunda é a ausência de instrumentação comum, que impede comparar resultados entre estudos. A terceira é o tratamento superficial dos fatores de licenciamento e sustentabilidade, que são mencionados mas não medidos.

Cabe destacar um achado específico. O trabalho de (TAST; MOSEVA, 2026), que é o antecedente mais próximo desta pesquisa por comparar Ceph, MinIO e OpenStack Swift, não realiza medição experimental: trata-se de análise comparativa de arquitetura e características. Não declara ferramenta de *benchmark* nem carga de trabalho. A comparação empírica entre alternativas de código aberto ao MinIO, no contexto de *Data Lake* híbrido, permanece portanto em aberto.

## 3.9 Derivação dos critérios do laboratório

Esta seção cumpre o compromisso assumido na Seção 1.6: nenhum elemento do laboratório é introduzido sem referência ao achado que o fundamenta. A Tabela 3.6 associa cada decisão do desenho experimental à questão de pesquisa e ao resultado correspondente.

Dois elementos da tabela não têm precedente na literatura recuperada: a avaliação do RustFS e o tratamento do risco de descontinuidade como critério de seleção. Ambos são registrados como contribuição original deste trabalho, e não como derivação de achado anterior.

## 3.10 Limitações do mapeamento

As decisões a seguir delimitam o alcance dos resultados apresentados e decorrem de escolhas de reprodutibilidade, viabilidade e escopo.

**Uso exclusivo da base OpenAlex.** Optou-se por consultar apenas a *API* pública da OpenAlex, sem recorrer a bases comerciais como ACM Digital Library, IEEE *Xplore* e Scopus. A escolha garante que a busca possa ser repetida por terceiros sem credencial institucional, o

**Tabela 3.6:** Derivação dos elementos do laboratório a partir dos achados do mapeamento.

| Elemento do laboratório | Origem | Fundamentação |
|---|---|---|
| MinIO como *baseline* | QP1 | Sistema mais avaliado na literatura (17 de 38 estudos) e origem do problema investigado |
| RustFS como alternativa | — | Definição prévia da pesquisa; nenhum estudo recuperado o avalia, o que caracteriza contribuição original |
| Ceph como alternativa | QP1 | Segundo sistema mais avaliado (11 de 38) e compatível com S3 via RGW |
| *Throughput* | QP2 | Métrica mais recorrente (16 de 38 estudos) |
| Latência | QP2 | Segunda métrica mais recorrente (14 de 38) |
| Consumo de CPU e memória | QP2 | Empregado em 5 estudos; necessário para avaliar custo operacional |
| Warp como instrumentação | QP3 | Ferramenta estabelecida mais utilizada para carga S3 (3 estudos) |
| Carga de metadados (1–64 KB) | QP3 | Regime recorrente nos estudos de objetos pequenos |
| Carga analítica (16–128 MB) | QP3 | Regime típico de leitura de arquivos em *Data Lake* |
| Carga de arquivos grandes | QP3 | Regime de transferência *multipart*, de 100 MB a 10 GB |
| Mínimo de 5 repetições | QP3 | Mediana observada entre os estudos que declaram repetições |
| Declaração explícita do procedimento | QP3 | 28 de 38 estudos omitem o número de repetições; 15 usam instrumentação própria não documentada |
| Licenciamento e governança | QP4 | Considerados em 20 estudos, porém sem medição sistemática |
| Risco de descontinuidade | QP5 | Nenhum estudo recuperado o trata como critério; contribuição original |

**Fonte:** Elaborado pelo autor (2026).

que não ocorre com consultas feitas em interfaces web proprietárias. A contrapartida é a possível ausência de trabalhos indexados apenas nessas bases.

**Teto de cem resultados por consulta.** Sete das dez consultas atingiram o teto, de modo que a coleta foi truncada por restrição de volume e não por esgotamento. Um teto maior recuperaria mais registros, ao custo de um volume e custo físico.

**Filtro automático de pertinência.** O descarte de 495 registros sem leitura individual pode ter removido trabalhos pertinentes que não empregassem a terminologia prevista. A amostragem manual de controle reduz, mas não elimina, esse risco.

**Triagem por um único pesquisador.** A seleção foi conduzida pelo autor, o que introduz risco de viés. O registro do critério aplicado em cada exclusão torna as decisões auditáveis, mas não substitui a revisão independente por um segundo pesquisador.

**Ausência de terceiro corte.** O funil encerrou-se com os 38 estudos aprovados no segundo estágio. O terceiro estágio consistiu em leitura dirigida para extração de dados, sem nova

exclusão.

**Literatura técnica fora do corpus.** Material técnico não revisado por pares sobre o RustFS e sobre a descontinuação do MinIO é utilizado na contextualização e na fundamentação teórica, mas não integra o conjunto de estudos primários do mapeamento.

# 4

# Metodologia

Este capítulo descreve o plano de análise e a metodologia experimental da pesquisa. Ele apresentará os resultados quantitativos e qualitativos, a comparação entre as soluções selecionadas e a discussão dos critérios de desempenho, compatibilidade, custos, licenciamento, maturidade, governança e sustentabilidade.

# 5

## Considerações finais

Como etapa preliminar, este trabalho delimita um estudo experimental comparativo de alternativas ao MinIO para armazenamento de objetos em arquiteturas de *Data Lake* híbridas. A conclusão definitiva será redigida após a realização do mapeamento sistemático, da experimentação e da análise comparativa previstos na metodologia.

# A

# Instrumentos do Mapeamento Sistemático

## A.1 Estudos primários selecionados

**Tabela A.1:** Estudos primários selecionados no mapeamento sistemático.

| Título | Ano | Veículo |
|---|---|---|
| Convergence of HPC and Cloud Storage Systems for Deep Learning Workflows: An Evaluation of LustreFS and S3-Compatible Object Storage | 2026 | IEEE Access |
| Lightweight Machine Learning-Based Dynamic Load Balancing for Distributed Object Storage Systems | 2026 | International Conference on Industrial Engineering and Operations Management (IEOM) |
| ObjectCache: Layerwise Object-Storage Retrieval for KV Cache Reuse | 2026 | arXiv (Cornell University) |
| BlobShuffle: Cost-Effective Repartitioning in Stream Processing Systems via Object Storage Exemplified with Kafka Streams | 2026 | arXiv (Cornell University) |
| Optimizing Object Storage Performance for Large File Uploading under Small-start Environments | 2026 | Journal of Information Processing |
| Comparative Analysis of Open-Source Object Data Storage Systems | 2026 | RUDN Journal of Engineering Researches |
| Trillion-scale integrated framework for high-throughput materials databases and seamless sharing | 2026 | Nature Communications |
| Merkle-Tree-Based Verifiable Public Data Auditing for Cloud Object Storage Using Smart Contracts | 2026 | arXiv (Cornell University) |
| Modular Blockchain-Based Data Tampering Detection for Storage Systems | 2026 | Portuguese National Funding Agency for Science, Research and Technology (RCAAP Project by FCT) |
| Análise de uma estratégia para alta disponibilidade de clusters CEPH | 2026 | Escola Regional de Alto Desempenho da Região Nordeste (ERAD-NE) |
| Design and Empirical Evaluation of a Network-Centric, On-Premises Architecture for Earth Observation Data Access | 2026 | arXiv (Cornell University) |

*continua na próxima página*

*continuação da página anterior*

| Título | Ano | Veículo |
|---|---|---|
| Oasis: Hiding the Cost of Querying Parquet Files in the Datapath | 2026 | arXiv (Cornell University) |
| From Ops to Dev: A Dual-Layer Programmable Data Lake With Kubernetes and WebAssembly-Based Offloading | 2026 | IEEE Access |
| Carbon Footprint and Carbon-Aware Selection of Document-Oriented, Relational, and Hybrid Object-Relational Storage for Image-Based Time-Series Workloads in Green IoT | 2026 | Research Square |
| Benchmarking Post-Quantum Key Encapsulation in S3-Compatible Object Storage under Client Concurrency | 2026 | arXiv (Cornell University) |
| Adaptive storage optimization for deep learning workloads in converged HPC-cloud environments: a reinforcement learning approach | 2026 | Scientific Reports |
| Empirical Evaluation of a Data Lakehouse Architecture for Streaming Industrial Data | 2026 | SSRN Electronic Journal |
| OASIS: Object-based Analytics Storage for Intelligent SQL Query Offloading in Scientific Tabular Workloads | 2025 | arXiv (Cornell University) |
| An End-to-End UAV–Cloud–AI Pipeline for Infrared-Based Real-Time Person Detection in SAR Missions | 2025 | ISPRS annals of the photogrammetry, remote sensing and spatial information sciences |
| Building a modern data platform based on the data lakehouse architecture and cloud-native ecosystem | 2025 | Discover Applied Sciences |
| A Comparative Study of Delta Parquet, Iceberg, and Hudi for Automotive Data Engineering Use Cases | 2025 | International Journal of Computer Science and Engineering |
| Federated Access from DOE Labs to Distributed Storage in the EIC Era of Computing | 2024 | EPJ Web of Conferences |
| POSIX access to remote storage via OpenID Connect | 2024 | EPJ Web of Conferences |
| Implementation and Performance Analysis of Non-Blockchain-based and Blockchain-based Business Licensing Systems Using Hyperledger Fabric | 2024 | Indonesian Journal of Computer Science |
| FaaS and Furious: abstractions and differential caching for efficient data pre-processing | 2024 | IEEE International Conference on Big Data (BigData) |
| x Meta : SSD-HDD-hybrid Optimization for Metadata Maintenance of Cloud-scale Object Storage | 2024 | ACM Transactions on Architecture and Code Optimization |
| RemOrphan: Object Storage Sustainability Through Removing Offline-Processed Orphan Garbage Data | 2023 | IEEE Access |
| Objcache: An Elastic Filesystem over External Persistent Storage for Container Clusters | 2023 | arXiv (Cornell University) |
| LibCOS: Enabling Converged HPC and Cloud Data Stores with MPI | 2023 | International Conference on High Performance Computing in Asia-Pacific Region (HPC Asia) |

*continua na próxima página*

*continuação da página anterior*

| Título | Ano | Veículo |
|---|---|---|
| Performance Analysis of Storage Systems in Edge Computing Infrastructures | 2022 | Applied Sciences |
| Learnings from an Under the Hood Analysis of an Object Storage Node IO Stack | 2022 | arXiv (Cornell University) |
| Profiling and Improving the PyTorch Dataloader for high-latency Storage: A Technical Report | 2022 | arXiv (Cornell University) |
| DisTRaC: Accelerating High Performance Compute Processing for Temporary Data Storage | 2022 | arXiv (Cornell University) |
| Viability of S3 Object Storage for the ASC Program at Sandia | 2022 | Não informado |
| Analyzing the Performance of the S3 Object Storage API for HPC Workloads | 2021 | Applied Sciences |
| Improving Data Services of Mobile Cloud Storage with Support for Large Data Objects using OpenStack Swift | 2021 | International Journal of Advanced Computer Science and Applications |
| Preparing for HL-LHC: Increasing the LHCb software publication rate to CVMFS by an order of magnitude | 2021 | EPJ Web of Conferences |
| Pangeo Benchmarking Analysis: Object Storage vs. POSIX File System | 2020 | IEEE/ACM International Parallel Data Systems Workshop (PDSW) |

## A.2 Instrumentação e sistemas avaliados

**Tabela A.2:** Instrumentação e sistemas avaliados nos estudos primários.

| Título | Ferramenta | Sistemas |
|---|---|---|
| Convergence of HPC and Cloud Storage Systems for Deep Learning Workflows: An Evaluation of LustreFS and S3-Compatible Object Storage | MLPerf Storage Benchmark Suite | Lustre+MinIO, Ceph, XFS |
| Lightweight Machine Learning-Based Dynamic Load Balancing for Distributed Object Storage Systems | Warp | MinIO |
| ObjectCache: Layerwise Object-Storage Retrieval for KV Cache Reuse | vLLM, LMCache, NIXL microbenchmarks | ObjectCache, Ceph RGW, DAOS |
| BlobShuffle: Cost-Effective Repartitioning in Stream Processing Systems via Object Storage Exemplified with Kafka Streams | Theodolite, ShuffleBench | BlobShuffle, Kafka Streams, Flink, Spark Structured Streaming |
| Optimizing Object Storage Performance for Large File Uploading under Small-start Environments | Test script em Python, FastAPI, MinIO SDK, iperf3, Prometheus, Grafana | MinIO |

*continua na próxima página*

*continuação da página anterior*

| Título | Ferramenta | Sistemas |
|---|---|---|
| Comparative Analysis of Open-Source Object Data Storage Systems | NAO INFORMADO | Ceph, MinIO, OpenStack Swift |
| Trillion-scale integrated framework for high-throughput materials databases and seamless sharing | Harness customizado | DuckLake (Parquet, Object Storage), Redis, Spark, Dask, Slurm |
| Merkle-Tree-Based Verifiable Public Data Auditing for Cloud Object Storage Using Smart Contracts | Script proprio em Python, Hardhat, s3s-fs | Cloud Object Storage (s3s-fs, S3) |
| Modular Blockchain-Based Data Tampering Detection for Storage Systems | pytest, pytest-benchmark | MinIO S3, PostgreSQL, Redis |
| Análise de uma estratégia para alta disponibilidade de clusters CEPH | rados bench, fio | Ceph RADOS |
| Design and Empirical Evaluation of a Network-Centric, On-Premises Architecture for Earth Observation Data Access | Warp, Script proprio de replicacao multi-site | MinIO |
| Oasis: Hiding the Cost of Querying Parquet Files in the Datapath | DuckDB async I/O extension | Oasis, S3, NVMe RDMA storage server |
| From Ops to Dev: A Dual-Layer Programmable Data Lake With Kubernetes and WebAssembly-Based Offloading | Warp | Connected Data Lake, MinIO |
| Carbon Footprint and Carbon-Aware Selection of Document-Oriented, Relational, and Hybrid Object-Relational Storage for Image-Based Time-Series Workloads in Green IoT | CodeCarbon, Benchmark harness customizado em Python | PostgreSQL, MongoDB, Hybrid (PostgreSQL + MinIO) |
| Benchmarking Post-Quantum Key Encapsulation in S3-Compatible Object Storage under Client Concurrency | Harness em Python com MinIO SDK, liboqs, pyca/cryptography, Prometheus | MinIO |
| Adaptive storage optimization for deep learning workloads in converged HPC-cloud environments: a reinforcement learning approach | MLPerf Storage Benchmark Suite, Harness RL | Garage Object Store, LustreFS, Ceph S3 |
| Empirical Evaluation of a Data Lakehouse Architecture for Streaming Industrial Data | k6 | Delta Lake, MinIO, Apache Kafka, Apache Spark Structured Streaming |
| OASIS: Object-based Analytics Storage for Intelligent SQL Query Offloading in Scientific Tabular Workloads | Spark Benchmark Suite | OASIS, MinIO, Ceph S3 Select, SkyhookDM |
| An End-to-End UAV–Cloud–AI Pipeline for Infrared-Based Real-Time Person Detection in SAR Missions | Script proprio de inferencia | Cloud Object Storage (S3, MinIO) |
| Building a modern data platform based on the data lakehouse architecture and cloud-native ecosystem | Apache JMeter 5.5 | MinIO, Dremio, Apache Iceberg |

*continua na próxima página*

*continuação da página anterior*

| **Título** | **Ferramenta** | **Sistemas** |
|---|---|---|
| A Comparative Study of Delta Parquet, Iceberg, and Hudi for Automotive Data Engineering Use Cases | Apache Spark 3.3.0 standalone | Delta Parquet, Apache Iceberg, Apache Hudi |
| Federated Access from DOE Labs to Distributed Storage in the EIC Era of Computing | S3bench | Ceph S3, MinIO GW |
| POSIX access to remote storage via OpenID Connect | FIO | Ceph RADOS GW (S3), StoRM-WebDAV, MinIO |
| Implementation and Performance Analysis of Non-Blockchain-based and Blockchain-based Business Licensing Systems Using Hyperledger Fabric | Apache JMeter | Hyperledger Fabric, MySQL, OpenStack Swift |
| FaaS and Furious: abstractions and differential caching for efficient data pre-processing | Benchmark customizado em Python | AWS S3, SSD local, Arrow Flight, Arrow IPC |
| x Meta : SSD-HDD-hybrid Optimization for Metadata Maintenance of Cloud-scale Object Storage | COSBench | xCeph (xMeta), Ceph BlueStore |
| RemOrphan: Object Storage Sustainability Through Removing Offline-Processed Orphan Garbage Data | Script proprio | OpenStack Swift |
| Objcache: An Elastic Filesystem over External Persistent Storage for Container Clusters | Script proprio | Objcache, S3FS (IBM Cloud Object Storage) |
| LibCOS: Enabling Converged HPC and Cloud Data Stores with MPI | IOR, Genseq, HACC | LibCOS (MinIO S3) |
| Performance Analysis of Storage Systems in Edge Computing Infrastructures | Script proprio em Python | MinIO, BigchainDB, IPFS |
| Learnings from an Under the Hood Analysis of an Object Storage Node IO Stack | YCSB MinIO workload engine | MinIO |
| Profiling and Improving the PyTorch Dataloader for high-latency Storage: A Technical Report | PyTorch Lightning Profiler, Dataset benchmark customizado | AWS S3, Ceph OS, Ceph FS, Gluster FS, Scratch local |
| DisTRaC: Accelerating High Performance Compute Processing for Temporary Data Storage | Savu, Python benchmark suite | Ceph RGW, GPFS, GRAM, ZRAM, BRD |
| Viability of S3 Object Storage for the ASC Program at Sandia | 05_ceph_benchmark, 06_aws_benchmark, 06a_posix_benchmark | NetApp StorageGRID, Dell EMC Elastic Cloud Storage, Ceph S3, POSIX |
| Analyzing the Performance of the S3 Object Storage API for HPC Workloads | IO500, IOR, MDTest, MDWorkbench, cosbench | MinIO, OpenStack Swift, Scality Ring, S3Embedded, LustreFS |
| Improving Data Services of Mobile Cloud Storage with Support for Large Data Objects using OpenStack Swift | Script proprio em Python, Mobile Sync Framework | OpenStack Swift, Parse Server, BaasBox |

*continua na próxima página*

*continuação da página anterior*

| **Título** | **Ferramenta** | **Sistemas** |
|---|---|---|
| Preparing for HL-LHC: Increasing the LHCb software publication rate to CVMFS by an order of magnitude | Script proprio CVMFS | Ceph S3 (radosgw), ZFS |
| Pangeo Benchmarking Analysis: Object Storage vs. POSIX File System | Pangeo Benchmarking Suite | Quantum ActiveScale S3, GPFS (POSIX DDN) |

# Referências

ABDEL Raziq Al Otaibi, A. **Implementación de un pipeline ELT en un entorno Data Lakehouse con MinIO, Airflow, DBT y Dremio**. 2026. Dissertação (Mestrado em Ciência da Computação) — Universidad Rey Juan Carlos.

DevPro. **MinIO container images gone? Best alternatives (2025)**. 2025.

FAUN Dev. **MinIO ends community development, positions AIStor as the future**. 2026.

KITCHENHAM, B. et al. Systematic literature reviews in software engineering — a tertiary study. **Information and Software Technology**, [S.l.], v.52, n.8, p.792–805, 2010.

MinIO, Inc. **MinIO GitHub Repository — THIS REPOSITORY IS NO LONGER MAINTAINED**. Repositório arquivado em 12 de fevereiro de 2026, GitHub.

PETERSEN, K.; VAKKALANKA, S.; KUZNIARZ, L. Guidelines for conducting systematic mapping studies in software engineering: an update. **Information and Software Technology**, [S.l.], v.64, p.1–18, 2015.

TAST, S. A.; MOSEVA, M. S. Comparative Analysis of Open-Source Object Data Storage Systems. **RUDN Journal of Engineering Research**, [S.l.], v.27, n.2, p.193–202, 2026.

WOHLIN, C. Guidelines for Snowballing in Systematic Literature Studies and a Replication in Software Engineering. In: INTERNATIONAL CONFERENCE ON EVALUATION AND ASSESSMENT IN SOFTWARE ENGINEERING (EASE), 18., New York, NY, USA. **Proceedings...** ACM, 2014. p.38:1–38:10. (EASE '14).